

Séance 3- Statistique descriptive univariée

Objectif de la séance : Apprendre à décrire et à résumer une série de données géographiques à l'aide des principaux indicateurs de statistique descriptive, et savoir les calculer sous Excel.

3.1. Pourquoi utiliser la statistique descriptive ?

Un jeu de données géographiques peut contenir plusieurs dizaines, centaines ou milliers de valeurs. Il est alors difficile de comprendre sa structure simplement en observant un tableau.

La **statistique descriptive** permet de résumer ces données à l'aide de quelques indicateurs. Elle permet notamment de répondre à des questions simples :

- Quelle est la valeur moyenne ?
- Quelle est la valeur centrale ?
- Quelles valeurs apparaissent le plus souvent ?
- Les valeurs sont-elles proches les unes des autres ou très dispersées ?
- Existe-t-il des valeurs particulièrement faibles ou élevées ?

Lorsque l'on étudie une seule variable à la fois, on parle de **statistique descriptive univariée**.

Par exemple, on peut étudier la population des communes d'un département, le taux de chômage des régions françaises ou encore le revenu médian des communes.

3.2. Effectifs et fréquences

Une première manière de décrire des données consiste à compter le nombre d'observations correspondant à une valeur ou à une catégorie.

L'**effectif** correspond au **nombre d'individus statistiques** présentant une valeur ou appartenant à une catégorie donnée. Par exemple, si 8 communes sur 20 appartiennent à la catégorie « espace rural », l'effectif de cette catégorie est de **8 communes**.

La **fréquence** correspond à la part que représente cet effectif dans l'ensemble des observations. Elle peut être exprimée sous forme de proportion ou de pourcentage.

Dans notre exemple : **Fréquence = 8 / 20 = 0,4 = 40 %**

Cela signifie que **40 % des communes étudiées appartiennent à la catégorie « espace rural »**.

Sous Excel, les effectifs et les fréquences peuvent être calculés à l'aide de différentes fonctions de comptage ou à l'aide d'un **tableau croisé dynamique**.

Ces premiers calculs permettent déjà de mieux comprendre la répartition des observations dans un jeu de données.

3.3. Les mesures de tendance centrale

Les mesures de tendance centrale permettent de résumer une série de données à l'aide d'une valeur représentative.

Les trois principales sont **la moyenne, la médiane et le mode**.

La moyenne. La moyenne correspond à la somme de toutes les valeurs divisée par le nombre d'observations. Par exemple, pour trois communes ayant respectivement 2 000, 4 000 et 6 000 habitants :

Moyenne = (2 000 + 4 000 + 6 000) / 3 = 4 000 habitants

La moyenne est très utilisée, mais elle est **sensible aux valeurs extrêmes**. Une valeur exceptionnellement élevée ou faible peut donc fortement la modifier.

La médiane. La médiane est la valeur qui **partage une série ordonnée en deux groupes de même effectif**.

Cela signifie qu'environ 50 % des observations se trouvent en dessous de la médiane et 50 % au-dessus.

Contrairement à la moyenne, la médiane est **peu sensible aux valeurs extrêmes**. Elle est donc particulièrement utile lorsque les données sont très inégalement réparties.

Le mode. Le mode correspond à **la valeur ou à la catégorie qui apparaît le plus souvent** dans une série.

Par exemple, dans la série : **2 – 3 – 3 – 4 – 5**, le mode est **3**, car cette valeur apparaît deux fois.

NB : Le mode peut être utilisé avec des données **qualitatives ou quantitatives**.

3.4. Exemple : moyenne, médiane et valeur extrême

Prenons la population de **7 communes**, exprimée en milliers d'habitants : **2 – 3 – 3 – 4 – 5 – 6 – 40**

La moyenne est : $\text{Moyenne} = (2 + 3 + 3 + 4 + 5 + 6 + 40) / 7 = 9$. La population moyenne est donc de **9 000 habitants**.

La médiane est **4**, car il s'agit de la valeur située au centre de la série ordonnée. La population médiane est donc de **4 000 habitants**.

Le mode est **3**, puisque cette valeur apparaît deux fois.

On obtient donc :

Moyenne : 9 000 habitants

Médiane : 4 000 habitants

Mode : 3 000 habitants

Pourquoi la moyenne est-elle beaucoup plus élevée que la médiane ?

La commune de **40 000 habitants** constitue une valeur très élevée par rapport aux autres communes. Elle **tire la moyenne vers le haut**, alors qu'elle influence beaucoup moins la médiane.

Cet exemple montre pourquoi il est important de **ne pas utiliser uniquement la moyenne pour décrire une série statistique**.

3.5. Les mesures de dispersion

Connaître la moyenne ou la médiane ne suffit pas toujours. Il faut également savoir si les observations sont **proches les unes des autres ou très différentes**. C'est ce que permettent de mesurer les **indicateurs de dispersion**.

L'étendue. L'étendue correspond à la différence entre la valeur maximale et la valeur minimale.

Dans notre exemple : **Étendue = 40 – 2 = 38**

Elle permet d'avoir une première idée de l'écart entre les valeurs extrêmes de la série. Elle reste cependant très sensible aux valeurs extrêmes.

La variance. La variance mesure la dispersion des observations autour de la moyenne. Plus la variance est élevée, plus les valeurs sont éloignées de la moyenne.

Son interprétation directe est cependant peu intuitive, car elle est exprimée dans **l'unité de la variable au carré**. C'est pourquoi on utilise souvent davantage l'écart-type.

L'écart-type. L'écart-type est calculé à partir de la variance. Il indique à quel point les observations sont dispersées autour de la moyenne. Un **écart-type faible** indique que les valeurs sont relativement proches de la moyenne. Un **écart-type élevé** indique que les valeurs sont davantage dispersées.

Son principal avantage est qu'il s'exprime dans **la même unité que la variable étudiée**. Par exemple, si l'on étudie une population exprimée en habitants, l'écart-type est également exprimé en habitants.

Le coefficient de variation. Le coefficient de variation rapporte l'écart-type à la moyenne :

$$\text{Coefficient de variation} = (\text{écart-type} / \text{moyenne}) \times 100$$

Il est exprimé en pourcentage. Il permet d'évaluer la **dispersion relative** d'une série et peut être utile pour comparer la variabilité de séries dont les moyennes ou les unités sont différentes.

Plus le coefficient de variation est élevé, plus les données sont dispersées relativement à leur moyenne.

3.6. La distribution statistique

Les indicateurs calculés précédemment permettent de résumer une série statistique. Cependant, ils ne suffisent pas toujours à comprendre **comment les valeurs sont réparties dans l'ensemble de la série**.


La **distribution statistique** décrit la manière dont les valeurs d'une variable se répartissent entre les observations.

Pour une variable quantitative, cette distribution peut notamment être représentée à l'aide d'un **histogramme**. Les valeurs sont alors regroupées en **classes**, et l'histogramme permet d'observer le nombre ou la fréquence des observations appartenant à chaque classe.


L'observation de la distribution permet notamment de repérer :

- une concentration des valeurs autour de certaines valeurs ;
- une distribution plus ou moins symétrique ou dissymétrique ;
- une dispersion importante ou faible ;
- la présence éventuelle de valeurs extrêmes.

La forme observée dépend également du **nombre de classes** et de leur **amplitude**. Un nombre trop faible de classes simplifie fortement la distribution et peut masquer certaines différences. À l'inverse, un nombre trop élevé de classes peut rendre sa lecture plus difficile.



Le choix des classes cherche donc un équilibre entre **simplification de l'information et conservation de la structure des données**.



On parle aussi de distribution dissymétrique/asymétrique à droite/gauche

3.7. Pourquoi ces indicateurs sont-ils utiles en cartographie ?

Ces calculs statistiques ne servent pas uniquement à décrire les données. Ils permettent également de **préparer leur représentation cartographique**.

Avant de construire une carte, il est important de connaître la distribution des valeurs : leur moyenne, leur médiane, leur dispersion, la forme de leur distribution et la présence éventuelle de valeurs extrêmes.

Il est également important de distinguer les **effectifs bruts** des **valeurs relatives** telles que les proportions ou les pourcentages. Un effectif indique un **volume**, tandis qu'une proportion indique le **poids relatif** d'un phénomène. Cette distinction est essentielle lorsque l'on souhaite comparer des territoires de tailles différentes.

L'analyse de la distribution permet ensuite de réfléchir à la manière de **regrouper les valeurs en classes** pour les représenter sur une carte. Cette opération, appelée **discrétisation**, sera étudiée plus précisément lors de la séance 6.

La statistique constitue donc une étape importante entre **les données brutes et leur représentation cartographique**.

À retenir

1. La **statistique descriptive univariée** permet de décrire et de résumer une variable à l'aide de quelques indicateurs.
2. **Effectif et fréquence** permettent de connaître l'importance d'une valeur ou d'une catégorie dans un ensemble d'observations.
3. **Moyenne, médiane et mode** ne donnent pas la même information. La moyenne est notamment plus sensible aux valeurs extrêmes que la médiane.
4. **Étendue, variance et écart-type** permettent d'évaluer la dispersion des observations. Le **coefficient de variation** mesure cette dispersion relativement à la moyenne.
5. L'analyse statistique permet de **mieux comprendre les données avant de les cartographier** et prépare notamment au travail de discrétisation.

TD / Activité pratique

À partir du jeu de données sociodémographiques utilisé lors de la **séance 2**, les étudiant-es réalisent une première analyse statistique sous **Excel**.

Ils doivent d'abord sélectionner une ou plusieurs variables quantitatives et identifier **l'unité statistique, la variable et son unité de mesure**.

Ils calculent ensuite :

effectif → **minimum** → **maximum** → **étendue** → **moyenne** → **médiane** → **écart-type** → **coefficient de variation**

Les calculs sont réalisés à l'aide des fonctions d'Excel, notamment **NB, MIN, MAX, MOYENNE, MEDIANE VARIANCE et ECARTYPE.P**.

Enfin, les étudiant-es doivent **interpréter les résultats obtenus** : la moyenne et la médiane sont-elles proches ? Les données sont-elles fortement dispersées ? Observe-t-on des valeurs particulièrement élevées ou faibles ?

L'objectif n'est donc pas seulement de **savoir utiliser les fonctions d'Excel**, mais surtout de **comprendre ce que les résultats statistiques nous apprennent sur les territoires étudiés**.